

RELATÓRIO SOBRE TRABALHO FINAL DE AED

**Zico Bettencourt de
Faria Costa**

zico@matematica.uff.br

RESUMO

Este estudo buscou analisar a base de dados referente às músicas mais tocadas na plataforma, no ano de 2023, disponibilizada pelo Spotify. Dentre todas as categorias referentes a cada música, três em específico foram investigadas neste trabalho, sendo elas “danceability_”, “valence_” e “energy_”. O que são tais categorias? Como são medidas? Como estão relacionadas? Estas são apenas algumas perguntas que esta análise busca investigar, e afirmar o que for possível com as informações divulgadas. No início deste artigo temos a Introdução, onde é explicitado mais precisamente as informações referentes a base de dados utilizada, o contexto que foi realizado este trabalho e sua particularização. Após temos a Primeira Análise, na qual é realizado a limpeza dos dados e uma primeira investigada em tais categorias, para entender como prosseguir para uma análise mais profunda. Na parte de Análise Conjunta, se investigou como as variáveis estavam relacionadas entre si, calculando correlações e observando tabelas. Por fim, a Análise Individual buscou utilizar as informações obtidas anteriormente para inferir o possível sobre cada categoria.

1. INTRODUÇÃO

Este trabalho da disciplina de Análise Exploratória de Dados, ministrada pelo professor Hugo Carvalho na UFRJ em 2026, consiste em analisar a base de dados disponibilizada pelo Spotify referente as músicas mais tocadas na plataforma, no ano de 2023. O arquivo se encontra disponível em <https://www.kaggle.com/datasets/nelgiriwithana/top-spotify-songs-2023/>. Esta base de dados possui diversas categorias relacionadas a cada música, como tom da música, batidas por minuto, data de lançamento, presença em playlists, e outras mais. Com estes dados é possível fazer diversas análises para tentar identificar padrões, como preferências por estilos musicais, artistas e etc. Em particular, este trabalho busca analisar e entender as categorias “danceability_”: Porcentagem indicando quão adequada a música é para dançar, valence_: Positividade do conteúdo musical da música e energy_: Nível percebido de energia da música. Em uma primeira visualização, fica a dúvida de como é medida tais categorias, e quais métricas são utilizadas, visto que não podemos simplesmente contar o nível de dançabilidade de uma música igual contamos em quantas playlists ela está presente.

2. PRIMEIRA ANÁLISE

2.1 Limpeza dos Dados

Primeiramente, foi realizada uma análise na base para identificar valores faltantes. Como os valores faltantes estavam sinalizados como uma string vazia, foi feita uma transformação das strings vazias para valores “NAs” através de um código em R {1} (todos os códigos sinalizados entre {} estão no fim do relatório.). Após foi possível identificar que somente a coluna Key (tom da música) possuía valores faltantes. Fica a reflexão se as músicas com valores de Key não preenchidos são músicas sem tom como raps e etc, músicas modais (apesar de terem um tom de repouso) ou apenas não foram coletadas. Como não temos acesso aos critérios usados, não podemos afirmar nada.

2.2 Categorias Principais

Como este trabalho é focado nas categorias “danceability_”, “valence_” e “energy_”, foi feita uma primeira análise das principais estatísticas dessas três classes quantitativas, como mediana, média, quantis e etc, utilizando o comando summary {2} nativo do R, e como resultado foi gerada esta tabela (ver Tabela 1):

	Danceability	Valence	Energy
Min	23.00	4.00	9.00
1st Qu	57.00	32.00	53.00
Median	69.00	51.00	66.00
Mean	66.98	51.41	64.27
3rd Qu	78.00	70.00	77.00
Max	96.00	97.00	97.00

Tabela 1. Tabela das principais estatísticas das 3 categorias de análise

Olhando somente esta tabela, não foi possível identificar nenhuma característica fora do comum, e como este banco de dados é somente das músicas mais escutadas, e não de todas as músicas, não temos como saber por exemplo se 23.00 de danceability (o mínimo registrado), é um valor extremamente baixo ou médio, em comparação com outras músicas.

Após esta primeira análise numérica, foi-se atrás de uma estatística visual, analisando os gráficos de histograma das mesmas categorias, através de um comando da biblioteca ggplot2 do R {3}:




Figura 1. Histograma da categoria “danceability_.”




Figura 2. Histograma da categoria “valence_.”




Figura 3. Histograma da categoria “energy_.”

Agora sim, analisando estes três gráficos, pode-se finalmente tirar as primeiras conclusões: Os usuários do Spotify aparentam ter preferência por músicas mais “dançáveis” e “energéticas”, e parecem não se importar com a “positividade” da música. Olhando os gráficos, nota-se no centro de cada categoria, um valor discrepante dos demais, como não temos acesso ao sistema de medição de cada categoria, não podemos afirmar se são valores faltantes preenchidos com a mediana, se é apenas um erro, ou a métrica usada facilita isto... Fica a reflexão.

3. ANÁLISE CONJUNTA

3.1 Primeira Correlação

Nestas primeiras observações, notou-se uma maior presença de músicas com “dançabilidade” e “energia” altas (ver Figura 1 e Figura 3), logo em seguida verificou-se se estão relacionadas, através do cálculo da correlação entre tais variáveis {4}, cujo resultado foi de 0.198484882122059, associado ao gráfico {5}:




Figura 4. Gráfico de correlação das categorias “danceability_.” e “energy_.”

Com tais resultados, podemos inferir com tamanha certeza que as categorias “danceability_.” e “energy_.” não estão relacionadas, e o fato de ambas apresentarem valores altos é provavelmente uma coincidência.

3.2 Correlação Geral

Seguindo a análise das correlações, e utilizando da poderosa ferramenta “ggpairs()” da biblioteca GGally em R, foi possível gerar uma única imagem contendo uma tabela de correlação de todas as variáveis quantitativas presentes {6}, e recortar para as correlações das três categorias de análise com as demais categorias quantitativas do banco de dados:




Figura 5. Correlação das categorias “danceability_”, “energy_” e “valence_” com demais categorias quantitativas

Em uma primeira vista, não é possível perceber nenhuma correlação significativa, e todas as variáveis aparentam ser independentes, porém podemos destacar três, que apesar de não terem valor absoluto alto o suficiente para se afirmar uma correlação: “energy_” x “acousticness_” com correlação de -0.577, “danceability_” x “valence_” com correlação de 0.410 e “energy_” x “valence_” com correlação de 0.358. A primeira delas parece fazer sentido intuitivamente, pois é de se esperar que uma música acústica não seja tão “energética”. As outras duas nos leva a inferir certas coisas sobre a métrica usada para medir a positividade da música (“valence_”): Parece que a positividade da música é quantificada levando em conta sua harmonia e melodia, não somente uma letra positiva (se é que a letra da música é levada em conta).

4. ANÁLISE INDIVIDUAL

4.1 Valence_.

Investigando a hipótese levantada no último parágrafo, de que a positividade da música está mais associada a harmonia e melodia do que com a letra, e olhando as músicas com “valence_” mais altas através do R {7}

track_name	artist.s_name	danceability_	valence_	energy_
<chr>	<chr>	<int>	<int>	<int>
Zona De Perigo	Leo Santana	81	97	77
Doja	Central Cee	91	97	57
There's Nothing Holdin' Me Back	Shawn Mendes	86	97	80
En El Radio Un Cochinerio	Victor Cibrán	70	97	62
JGL	Luis R Conriquez, La Adictiva	70	97	59

Figura 6. Cinco músicas com maior valor em “valence_”

A quarta música “En El Radio Un Cochinerio” fala sobre troca de tiros, fuga e milícia, com trechos traduzidos como: “Vesti um colete à prova de balas - Saquei a Glock e aponte, mas meu dedo tremia - Escutei uma derrapada e os vi de longe - Começou a rajada de tiros, uma chuva de balas - Várias acertavam no vidro” o que pode-se considerar que não é uma letra nada positiva. Analisando músicas com “positividade” alta encontra-se várias outras com letras “pesadas”, como “The Real Slim Shade” do rapper Eminem, que tem uma letra bastante violenta repleta de agressões verbais, e possui um incrível valor de 78 em “valence_”. Logo podemos afirmar com alguma certeza que a métrica usada para medir a “positividade” da música não leva/ leva muito pouco em conta a letra da música.

4.2 Danceability_.

Analisando as músicas mais dançáveis deste banco de dados, adaptando o último código utilizado {8}, nota-se a forte presença de funks e raps, o que é interessante pois em geral funks são extremamente dançáveis e raps o contrário, porém o que ambos têm em comum é a presença de uma batida forte e marcante, e uma pulsação rítmica mais acelerada, levantando a hipótese de que esta seja a característica de maior peso utilizada na métrica para medir “danceability_”. Esta hipótese se confirma ainda mais quando se escuta a música mais dançável desta base de dados, que é Peru do cantor Ed Sheeran, com 96 de “dançabilidade”. Ao ouvir esta música, percebe-se que ela é uma música melódica e calma, não muito dançável aparentemente, porém ela possui uma batida forte e alta regendo a música do início ao fim, o que fortalece a hipótese levantada anteriormente.

track_name	artist.s._name	danceability_.	valence_.	energy_.
<chr>	<chr>	<int>	<int>	<int>
Peru	Ed Sheeran, Fireboy DML	96	71	42
Players	Coi Leray	95	62	52
The Real Slim Shady	Eminem	95	78	66
CAIRO	Karol G, Ovy On The Drums	95	43	69
Super Freaky Girl	Nicki Minaj	95	91	89
Starlight	Dave	95	36	37
Al Preto	L7nnon, DJ Biel do Furduncinho, Bianca	95	83	57
Slut Me Out	NLE Choppa	94	71	61
Gol Bolinha, Gol Quadrado 2	Mc Pedrinho, DJ 900	93	68	65
Shorty Party	Cartel De Santa, La Kelly	93	47	47
Forgot About Dre	Eminem, Dr. Dre	93	61	74
sentaDONA (Remix) s2	Lu🎧sa Souza, MC Frog, Dj Gabriel do Borel, Davi K	93	77	45
Privileged Rappers	Drake, 21 Savage	93	62	61
Sprinter	Dave, Central Cee	92	66	58
AMARGURA	Karol G	92	55	70
Without Me	Eminem	92	67	66

Figura 7. Músicas mais dançáveis do dataframe

4.3 Energy_.

E por fim, analisando as músicas mais energéticas desta base de dados {9}, encontra-se majoritariamente músicas eletrônicas, com uma pulsação rítmica muito acelerada, e bastante presença sonora, como distorções e sonoridades geradas digitalmente.

track_name	artist.s._name	danceability_.	valence_.	energy_.
<chr>	<chr>	<int>	<int>	<int>
I'm Good (Blue)	Bebe Rexha, David Guetta	56	38	97
Murder In My Mind	Kordhell	71	57	97
T🎧	dennis, MC Kevin o Chris	86	59	96
That That (prod. & feat. SUGA of BTS)	PSY, Suga	91	91	96
Bombonzinho - Ao Vivo	Israel & Rodolfo, Ana Castela	65	72	95
🎧🎧🎧🎧🎧🎧🎧🎧	YOASOBI	57	84	94
Hype Boy	NewJeans	59	78	94
KICK BACK	Kenshi Yonezu	58	29	94

Figura 8. Músicas mais energéticas do dataframe

Inferese então que seja esta a métrica utilizada para medir a energia da música: Presença sonora e aceleração da pulsação rítmica.

5. CONCLUSÃO

Concluindo este trabalho, pode-se notar que não foi possível afirmar com certeza qual a métrica utilizada para medir as três categorias de análise (“danceability_.”, “valence_.” e “energy_.”), pois isto só seria possível se o Spotify divulgasse-as, porém foi possível colher informações suficientes para inferir certas características sobre tais métricas, nos levando ao entendimento maior de como foi calculado cada valor presente nestas variáveis nas músicas.

CÓDIGOS

```
{0}:

INSTALL.packages ("TIDYVERSE")

INSTALL.packages ("VISDAT")

INSTALL.packages ("GGALLY")

library (TIDYVERSE)

library (VISDAT)

library (GGALLY)

library (DPLYR)

DF <-
  read.csv ("https://github.com/HugoCarvalhoUFRJ/aed/raw/refs/heads/main/materiais-didaticos/spotify-2023-mod.csv",
    header = TRUE, sep = ',', dec = '.')

{1}:

DF <- DF %>%

  mutate (across (where (is.character), ~na_if (., "")))

{2}:

summary (DF)

{3}:

options (repr.plot.width = 10, repr.plot.height = 6)

ggplot (DF,

  aes (x = danceability_)) + geom_histogram (fill = 'green', color = 'black', bins = 73)

ggplot (DF,

  aes (x = valence_)) + geom_histogram (fill = 'green', color = 'black', bins = 93)

ggplot (DF,

  aes (x = energy_)) + geom_histogram (fill = 'green', color = 'black', bins = 88)

{4}:

cor (DF$danceability_, DF$energy_)
```

{5}:

```
GGPLOT (DF,

        AES (X = DANCEABILITY_., Y = ENERGY_.) ) +

        GEOM_POINT ( )
```

{6}:

```
OPTIONS (REPR.PLOT.WIDTH = 25, REPR.PLOT.HEIGHT = 15)

DF %>%

    SELECT (DANCEABILITY_., ENERGY_., VALENCE_., BPM, ACOUSTICNESS_., INSTRUMENTALNESS_., LIVENESS_., SPEECHINESS_.,
STREAMS) %>%

    GGPAIRS ( )
```

{7}:

```
DF %>%

    SELECT (TRACK_NAME, ARTIST.S._NAME, DANCEABILITY_., VALENCE_., ENERGY_.) %>%

    ARRANGE (DESC (VALENCE_.) )
```

{8}:

```
DF %>%

    SELECT (TRACK_NAME, ARTIST.S._NAME, DANCEABILITY_., VALENCE_., ENERGY_.) %>%

    ARRANGE (DESC (DANCEABILITY_.) )
```

{9}:

```
DF %>%

    SELECT (TRACK_NAME, ARTIST.S._NAME, DANCEABILITY_., VALENCE_., ENERGY_.) %>%

    ARRANGE (DESC (ENERGY_.) )
```